作业一 文本分类实验报告

2312260 谭易 个人完成 2026年10月12日

实验目标与数据协议

本实验比较三种词袋表示、三种平均词向量表示以及 BERT 微调，在固定 NYT 测试集上报告 Accuracy 和 Macro-F1。全部数字均来自 artifacts/results 中的实测记录；未完成实验不会以推测值代替。

原始要求存在两处不完整：提到“三种 Bag-of-Words”但只列出 Binary 与 Word Frequency，因此补充标准 TF-IDF；“请统一设置”后未给出随机种子，因此固定为 42，并保存完整行号以便复现。

NYT 有 11,519 条，类别为 sports 8,639、politics 1,451、business 1,429；AG News 有 90,000 条。RandomState(42).permutation 随机打乱后，以 floor(0.8N)、floor(0.9N) 切分，训练/验证/测试分别为 9,215/1,152/1,152。未做分层抽样，符合先随机打乱的要求。

传统方法统一将文本转小写，以正则 [a-z]+(?:'[a-z]+)? 提取英文单词及内部撇号。保留停用词，不做词干化。词袋使用训练集所有出现的词（min_df=1）。测试集不参与词表、IDF、自训练 NYT 词向量、标准化或超参数拟合。

类别	训练集	验证集	测试集
business	1157	124	148
politics	1134	152	165
sports	6924	876	839

评价指标

Accuracy 为正确预测数量除以样本数量。对类别 c，Precision=TP/(TP+FP)，Recall=TP/(TP+FN)，F1=2PR/(P+R)；Macro-F1 对全部三类 F1 等权平均。体育类别占比接近四分之三，因此需要同时分析 Macro-F1 和少数类召回率，不能只报告准确率。

Task 1 词袋与逻辑回归

Binary BoW 使用词是否出现的 0/1 向量；Word Frequency 使用原始词频；TF-IDF 使用平滑 IDF：log((1+N)/(1+df))+1，再对文档向量进行 L2 归一化。三者都使用多项逻辑回归、L2 正则化和 lbfgs 优化器。

各方法独立在验证集选择 C∈{0.1,1,10}，按 Macro-F1 最大选取，分数相同时保留较小 C。max_iter=2000，tol=1e-4。模型仅在训练集训练，选出参数后不使用验证集重拟合，因此所有方法训练样本一致。

Task 2 平均词向量

GloVe 使用 Stanford 官方 glove.6B 的 100 维向量。程序仅加载本数据中出现的词以节省内存，不改动预训练参数。AG Word2Vec 在全部 90,000 条 AG 文本上训练；NYT Word2Vec 只在 9,215 条训练文本上训练。

Word2Vec 使用 Skip-gram，vector_size=100、window=5、min_count=2、negative=5、epochs=5、workers=1、seed=42。单线程和 PYTHONHASHSEED=42 用于降低非确定性。有效词向量按出现次数求算术平均；未登录词跳过，全未登录词文档映射为全零向量。

平均向量经仅在训练集拟合的 StandardScaler 标准化，再训练相同逻辑回归并以验证集选择 C。各划分的词覆盖率与零向量文档数保存在对应结果 JSON 中，便于解释语料差异。

Task 3 BERT 微调

使用指定 google-bert/bert-base-uncased 官方预训练权重，分类头输出三类。采用官方 WordPiece tokenizer，padding=max_length、truncation=True、max_length=64，包含特殊 token。所有 BERT 参数参与微调，不冻结编码器，不以更小模型替代。

训练恰好三轮，batch_size=16，AdamW 学习率 2e-5，weight_decay=0.01，10% warmup 后线性衰减，梯度范数裁剪为 1.0。每轮记录验证集 Macro-F1，三轮训练结束后选最佳验证检查点评测测试集。记录种子、运行设备、训练历史及原始模型 revision。

实测结果汇总

方法	Accuracy	Macro-F1	耗时 秒
binary	0.9878	0.9725	7.7
frequency	0.9905	0.9774	20.4
tfidf	0.9913	0.9803	6.9
glove	0.9887	0.9756	38.0
w2v_ag	0.9835	0.9637	88.0
w2v_nyt	0.9896	0.9769	138.5
bert	0.9748	0.9439	7313.6

验证集选择记录

方法	特征数 / 维数	选定 C	验证 Macro-F1
binary	64632	1.0	0.9723
frequency	64632	1.0	0.9668
tfidf	64632	10.0	0.9695
glove	100	0.1	0.9647
w2v_ag	100	10.0	0.9543
w2v_nyt	100	0.1	0.9698

比较与解释

词袋模型保留类别相关词的独立权重，适合主题分类。Binary 与 Frequency 的区别说明出现次数并非唯一决定因素；TF-IDF 的归一化可减弱长文档和通用词的影响。模型排名应由表中实测数值判断，不能根据参数规模预先确定。

平均词向量将任意长度文档压缩为 100 维，存储紧凑，但会丢失词序、词间组合及部分稀有类别词。AG 与 NYT 自训练词向量既有语料规模差异，也有领域差异，因此本实验无法把分数差唯一归因为“领域匹配”。

长度审计显示测试新闻平均 818.79 个 WordPiece（含特殊 token），全部 1,152 篇都超过 64。BERT 只读取前 64 个 WordPiece，而传统模型读取完整文本。表示方式和可见文本长度同时变化，不能把模型差异完全归于架构。数据较容易、类别较少时，预训练模型不一定优于线性基线。

类别级错误分析

真实类别 / 预测	business	politics	sports
business	140	7	1
politics	1	163	1
sports	0	0	839

行是真实类别，列是预测类别。少数类之间的误分比 sports 类别更值得关注。完整逐样本预测与每类指标均随代码提供，可按 row_id 回查原文。

数据质量与结果边界

原始 NYT 有 72 条重复文本（按 text 完全相同计数）；验证集有 12 条、测试集有 8 条文本在训练集中出现。主结果保留指定统一划分，补充在 1,144 条未见测试文本上的 TF-IDF Accuracy=0.9913、Macro-F1=0.9800。这项排除不能消除所有近重复或报道事件层面的泄漏。

本次只使用一个随机划分，没有以多次种子重复估计方差。总体准确率较高时，个别错例即可改变排名；不得将千分位差异表述为统计显著。原始数据的新闻来源和时间范围未由课程文件详细说明，不推断其代表全部 NYT 新闻。

训练耗时包含特征构建和调参，不等于纯模型优化时间。CPU 同时承担多个任务时，耗时不能作为严格硬件基准。实验不涉及事实核查、公平性保证或跨领域泛化证明。

复现与提交内容

环境：Windows，Python 3.10，CPU i7-13700H，16 GB RAM。精确包版本见 requirements-lock.txt。README 提供逐步运行命令及一键 PowerShell 入口。

src/common.py 负责固定划分和评价；train_classical.py 负责 Task 1/2；train_bert.py 负责 Task 3。artifacts/split.json 保存数据哈希和划分行号；artifacts/results 保存结果与逐样本预测。报告由 scripts/build_pdfs.py 从结果自动生成。

提交前应核对 BERT 与 GloVe 两行均为完整实测结果、源码可运行、GitHub 链接对助教可访问。原始提交登记表含其他同学个人信息，不属于作业交付内容。

引用与工具使用声明

Mikolov et al. 2013. Efficient Estimation of Word Representations in Vector Space. https://arxiv.org/abs/1301.3781

Pennington, Socher, and Manning. 2014. GloVe: Global Vectors for Word Representation. https://aclanthology.org/D14-1162/

Devlin et al. 2019. BERT: Pre-training of Deep Bidirectional Transformers for Language Understanding. https://aclanthology.org/N19-1423/

课程 CSV 和作业要求为任务来源；scikit-learn、Gensim、PyTorch、Transformers 提供算法库实现。使用 Codex 辅助实现、排查运行问题、整理结果和生成报告；实验数字由实际程序输出，本人提交前需审阅并能够解释全部核心内容。